

TEAM CHALLENGE: CONSTRUCCIÓN DE PIPELINES CON SCIKIT-LEARN

CONTENIDO

O1 Introducción y objetivo

O2 Pipelines

03

04


05

Aplicación de los pipelines

Resultados

Conclusiones





INTRODUCCIÓN Y OBJETIVO



Datos relacionados con las características de los vuelos y la satisfacción de sus clientes.



Determinar si los clientes estuvieron satisfechos o no en sus vuelos



PIPELINES




01.

Limpieza de Nulos y Duplicados




02.

Identificación de Tipos de Columnas



03.

Aplicar Logaritmo a Variables Numéricas




04.

Codificación y Escalado



05.

Entrenamiento y Selección del Mejor Modelo



O1. LIMPIEZA DE NULOS Y DUPLICADOS

```
# Limpieza de nulos y duplicados
class DropHighNullColumns(BaseEstimator, TransformerMixin):
   def __init__(self, threshold=0.15):
        self.threshold = threshold
       self.cols_to_drop = []
   def fit(self, X, y=None):
       null_percentage = X.isnull().mean()
       self.cols_to_drop = null_percentage[null_percentage > self.threshold].index.tolist()
       return self
   def transform(self, X):
        return X.drop(columns=self.cols_to_drop, errors="ignore")
class DropRemainingNulls(BaseEstimator, TransformerMixin):
   def fit(self, X, y=None):
       return self
   def transform(self, X):
       return X.dropna()
class DropDuplicates(BaseEstimator, TransformerMixin):
   def fit(self, X, y=None):
       return self
   def transform(self, X):
        return X.drop_duplicates()
null pipeline = Pipeline([
   ("drop_high_nulls", DropHighNullColumns(threshold=0.15)),
   ("drop_remaining_nulls", DropRemainingNulls()),
    ("drop duplicates", DropDuplicates())
df train cleaned = null pipeline.fit transform(df train)
df_train_cleaned.info()
```

02. IDENTIFICACIÓN DE TIPOS DE COLUMNAS

```
# Identificación de tipos de columnas
class IdentifyColumns(BaseEstimator, TransformerMixin):
    def fit(self, X, y=None):
        self.numerical_cols = ['Age', 'Flight Distance', 'Departure Delay in Minutes', 'Arrival Delay in Minutes']
       self.binary_cols = [col for col in X.select_dtypes(include=['object']).columns if X[col].nunique() == 2]
       if 'satisfaction' in self.binary cols:
            self.binary cols.remove('satisfaction')
        self.target = 'satisfaction'
        self.onehot_cols = [col for col in X.columns if col not in self.numerical_cols and col not in self.binary_cols and col != self.target]
        self.numerical cols log = [col for col in self.numerical cols if col != 'Age']
        return self
    def transform(self, X):
       return X
identify columns pipeline = IdentifyColumns()
identify columns pipeline.fit(df train cleaned)
numerical cols log = identify columns pipeline.numerical cols log
binary cols = identify columns pipeline.binary cols
onehot cols = identify columns pipeline.onehot cols
numerical cols = identify columns pipeline.numerical cols
```

print(f'Tipos de columnas identificadas correctamente.')

03. APLICAR LOGARITMO A VARIABLES NUMÉRICAS

```
# Aplicar Logaritmo a Variables Numéricas
def safe_log_transform(X):
    """Aplica np.log1p() solo a las columnas numéricas seleccionadas."""
    X = X.copy()
    if isinstance(X, pd.DataFrame):
        for col in numerical cols log:
            X[col] = pd.to_numeric(X[col], errors="coerce") # Convertir a float
            X[col] = np.log1p(X[col]) # Aplicar log1p
    else:
       X = np.log1p(X.astype(float)) # Para arrays numpy
    return X
log pipeline = FunctionTransformer(safe log transform)
df train cleaned[numerical cols log] = log pipeline.fit transform(df train cleaned[numerical cols log])
df train[numerical cols].hist(figsize = (5,5))
plt.tight layout
plt.show()
```



04. CODIFICACIÓN Y ESCALADO

```
# One hot encoding y estandarización
def label encode binary(X):
    X encoded = X.copy()
    for col in X encoded.columns:
        X_encoded[col] = X_encoded[col].astype("category").cat.codes
    return X encoded
def binarize_satisfaction(X):
    return X.replace({"neutral or dissatisfied": 0, "satisfied": 1}).infer_objects(copy=False)
preprocessor = ColumnTransformer([
    ("target", FunctionTransformer(binarize_satisfaction), ["satisfaction"]),
    ("binary", FunctionTransformer(label_encode_binary), binary_cols),
    ("onehot", Pipeline([
        ("encoder", OneHotEncoder(handle_unknown="ignore", sparse_output=True)),
        ("svd" TruncatedSVD(n_components=50)) # Reduce dimensiones para evitar MemoryError
    ]), onehot_cols),
    ("scaler", StandardScaler(), numerical_cols)
], remainder='passthrough')
preprocessing_pipeline = Pipeline([
    ("preprocessor", preprocessor)
])
df_train_transformed = preprocessing_pipeline.fit_transform(df_train_cleaned)
print(f'Columnas transformadas y estandarizadas.')
```

O5. ENTRENAMIENTO Y SELECCIÓN DEL MEJOR MODELO

```
# Train test split
train set, val set = train test split(df train transformed, test size=0.2, random state=42)
X_train = train_set[:, 1:]
y train = train set[:, 0]
X_val = val_set[:, 1:]
y val = val set[:, 0]
# Entrenamiento y selección del mejor modelo
models = {
    "RandomForest": RandomForestClassifier(),
    "GradientBoosting": GradientBoostingClassifier(),
    "LogisticRegression": LogisticRegression(),
    "LightGBM": lgb.LGBMClassifier()
scores = {}
for model name, model in models.items():
    pipeline model = Pipeline([("model", model)])
    pipeline model.fit(X train, y train)
    y_pred = pipeline_model.predict(X_val)
    balanced_acc = balanced_accuracy_score(y_val, y_pred)
    scores[model_name] = balanced_acc
    print(f"{model_name} - Balanced Accuracy: {balanced_acc:.4f}")
best_model_name = max(scores, key=scores.get)
print(f"\nModelo seleccionado para optimización: {best_model_name}")
param_grid = {
    "RandomForest": {"model__n_estimators": [50, 100, 200], "model__max_depth": [None, 10, 20]},
    "GradientBoosting": {"model__n_estimators": [50, 100], "model__learning_rate": [0.01, 0.1]},
    "LightGBM": {"model__num_leaves": [31, 50], "model__learning_rate": [0.01, 0.1]}
grid_search = GridSearchCV(Pipeline([("model", models[best_model_name])]), param_grid[best_model_name], cv=5, scoring="balanced_accuracy", n_jobs=-1)
grid search.fit(X train, y train)
```

CONSTRUCCIÓN DEL PIPELINE FINAL Y GUARDADO DEL MODELO

```
# Construcción del pipeline completo
full pipeline = Pipeline([
    ("null_handling", null_pipeline),
    ("column_identification", identify_columns_pipeline),
    ("log_transform", log_pipeline),
    ("preprocessor", preprocessing_pipeline),
    ("model", grid search.best estimator )
# Guardar el pipeline completo con dill
BASE_PATH - os.path.abspath(os.path.join(os.getcwd(), "..")) # Sube un nivel al directorio raíz del proyecto
MODEL DIR = os.path.join(BASE PATH, "models")
os.makedirs(MODEL DIR, exist ok=True)
model path = os.path.join(MODEL DIR, "best pipeline.pkl")
with open(model path, "wb") as f:
    dill.dump(full pipeline, f)
print(f"\nPipeline completo guardado en {model_path}")
```


APLICACIÓN DE LOS PIPELINES

```
# Filtrar FutureWarnings
warnings.filterwarnings("ignore", category=FutureWarning)
# Se asume que 'df test' ya está cargado y tiene 'id' como índice.
y test = df test["satisfaction"].replace({"neutral or dissatisfied": 0, "satisfied": 1}).infer objects(copy=False)
X test = df test.drop(columns=["satisfaction"])
# Añadir la columna dummy 'satisfaction' para que el pipeline procese los datos igual que en entrenamiento
X test pipeline = X test.copy()
X test pipeline["satisfaction"] = "neutral or dissatisfied"
# Recuperar la variable 'numerical cols log' desde el transformer 'column identification'
numerical cols log = best pipeline.named steps["column identification"].numerical cols log
# Obtener los índices de las filas que sobreviven la limpieza (nulos y duplicados)
X test clean = best pipeline.named steps["null handling"].transform(X test pipeline)
idx clean = X test clean.index
# Transformar hasta el preprocesador y remover la columna del target (posición 0)
X test transformed = best pipeline[:-1].transform(X test pipeline)
X test final = X test transformed[:, 1:]
# Realizar las predicciones con el modelo entrenado
y pred = best pipeline.named steps["model"].predict(X test final)
# Alinear y test con los índices de las filas procesadas
y test aligned = y test.loc[idx clean]
print(f';Los pipelines se han aplicado correctamente!')
```

RESULTADOS

	pr	ecision	recall	f1-score	support
	0	0.94	0.97	0.96	14528
	1	0.96	0.93	0.94	11365
accurac	:y			0.95	25893
macro av	g	0.95	0.95	0.95	25893
weighted av	g	0.95	0.95	0.95	25893

RESULTADOS



CONCLUSIONES

- Muy buen desempeño.
- Mejoras:
 - o Minimizar los falsos negativos ajustando el umbral de decisión.
 - o Optimizar los pesos en la función de pérdida.

MUCHAS GRACIAS

